

Uzakliklar, Norm, Benzerlik

Literatürdeki anlatım norm ve uzaklık konusu etrafında biraz kafa karışıklığı yaratabiliyor, bu yazıda biraz açıklık getirmeye çalışalım. Norm bir büyüklük ölçüsüdür. Vektör uzayları ile olan alakasını görmek için *Fonksiyonel Analiz* notlarına bakılabilir. Büyüklük derken bir x vektörünün büyüklüğünden bahsediyoruz, ki bu çoğunlukla $\|x\|$ gibi bir kullanımda görülür, eğer altsimge yok ise, o zaman 2 kabul edilir, yani $\|x\|_2$. Bu ifade bir L2 norm'unu ifade eder. $\|x\|_1$ varsa L1 norm'u olurdu.

L1, L2 normları, ya da genel olarak p üzerinden L_p normları şöyle gösterilir

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{1/p}$$

ki x_i , x vektörü içindeki öğelerdir. Eğer $p = 2$ ise, L2 norm

$$\|x\|_2 = \left(\sum_i |x_i|^2 \right)^{1/2}$$

Ustel olarak $1/2$ 'nin karekok demek olduğunu hatırlayalım, yani

$$\|x\|_2 = \sqrt{\sum_i |x_i|^2}$$

Bu norm ayrıca Oklitsel (Euclidian) norm olarak da bilinir, tabii ki bunun Oklitsel uzaklık ile yakın bağlantısı var (iki vektörü birbirinden çıkartıp Oklit normunu alırsak Oklit uzaklığını hesaplamış oluruz).

Eğer $p = 1$ olsaydı, yani L1 norm, o zaman ustel olarak $1/1$ olur, yani hiçbir ustel / kokselsel işlem yapılmasına gerek yoktur, iptal olurlar,

$$\|x\|_1 = \sum_i |x_i|^1$$

Örnek

$$a = \begin{bmatrix} 3 \\ -2 \\ 1 \end{bmatrix}$$

$$\|a\| = \sqrt{3^2 + (-2)^2 + 1^2} = 3.742$$

Örnekte altsimge yok, demek ki L2 norm.

Ek Notasyon, İşlemler

L1 normu için yapılan işlemi düşünelim, vektör öğeleri kendileri ile çarpılıyor ve sonuçlar toplanıyor. Bu işlem

$$\|x\|_1 = x^T x$$

olarak ta gösterilemez mi? Ya da $x \cdot x$ olarak ki bu noktasal çarpımdır.

Bazen de yapay öğrenim literatüründe $\|x\|^2$ şeklinde bir kullanım görebiliyorsunuz. Burada neler oluyor? Altsımg yok, demek ki L2 norm. Sonra L2 normun karesi alınmış, fakat L2 normu tanımına göre bir karekok almiyor muydu? Evet, fakat o zaman kare işlemi karekoku iptal eder, demek ki L2 normunun karesini almak bizi L1 normuna döndürür! Eh bu normu da $x^T x$ olarak hesaplayabildiğimize göre hemen o notasyona geçebiliriz, demek ki $\|x\|^2 = x^T x = x \cdot x$.

İkisel Vektörlerde Benzerlik

Diğer ilginç bir kullanım ikisel değerler içeren iki vektör arasında kaç tane 1 değerlerinin toplamını bulmak. Mesela

```
a = np.array([1,0,0,1,0,0,1,1])
b = np.array([0,0,1,1,0,1,1,0])
```

Bu iki vektör arasındaki 1 uyumunu bulmak için noktasal çarpım yeterli, çünkü 1 ve 0, 0 ve 1, 0 ve 0 çarpımı sıfır verir, ama 1 çarpı 1 = 1 sonucunu verir. O zaman L1 norm bize ikisel iki vektör arasında kabaca bir benzerlik fikri verebilir.

```
print np.dot(a,b)
```

2

Ortalama Çıkartmak

Scipy seyrek matrislerde ortalamayı almak kulfetli olabiliyor, Scipy ortalamayı çıkartmayı izin vermez (olmayan değerler ortalamaya alırken sıfır mı kabul edilecektir? bu tam bilinmediği için izin verilmemiş). Fakat bu özellik gerekiyorsa, şöyle yapılır,

```
import scipy.sparse as sps
```

```
def center(mat):
    mat = mat.T
    vec = sps.csc_matrix(mat.mean(axis=1))
    mat_row = mat.tocsr()
    vec_row = vec.T
    mat_row.data -= np.repeat(vec_row.toarray()[0], np.diff(mat_row.indptr))
    return mat_row.T
```

```
mat = sps.csc_matrix([[1, 2, 3, 5.],
                      [2, 3, 4, 5.],
                      [3, 4, 5, 5.]])
```

```
print center(mat).todense()
```

```
[[-1. -1. -1.  0.]
 [ 0.  0.  0.  0.]
 [ 1.  1.  1.  0.]]
```

Normalize Etmek

Standardize etmek hem ortalamayı çıkartmak (demean), sonra normalize etmek demektir. Bu iki işlem birbirinden bağımsız yapılabilir, bazen biri bazen diğeri kullanılabilir. Normalize etmek için scikit-learn paketinin fonksiyonları vardır,

```
from sklearn.preprocessing import normalize
print normalize(mat, norm='l1', axis=0).todense()
```

```
[[-0.5 -0.5 -0.5  0. ]
 [ 0.   0.   0.   0. ]
 [ 0.5  0.5  0.5  0. ]]
```

Ustteki çağrı matrisin kolonlarını (çünkü `axis=0` seçildi, bu kolon demek) L1 normu kullanarak normalize etti; yani her kolonun L1 büyüklüğü hesaplandı ve o kolonun her hücresi bu büyüklük ile bölündü. L2 norm kullanırdık,

```
print normalize(mat, norm='l2', axis=0).todense()

[[-0.70710678 -0.70710678 -0.70710678  0.          ]
 [ 0.          0.          0.          0.          ]
 [ 0.70710678  0.70710678  0.70710678  0.          ]]
```

Satırları normalize edebilirdik,

```
print normalize(mat, norm='l1', axis=1).todense()

[[-0.33333333 -0.33333333 -0.33333333  0.          ]
 [ 0.          0.          0.          0.          ]
 [ 0.33333333  0.33333333  0.33333333  0.          ]]
```